Informe y plan de ruta: motion prediction V2X

Nov 5, 2026 · @mario

Resumen: lo que te propongo

Mi recomendación es que tu primer paper de primer autor sea un benchmark V2X unificado, con calibración y robustez a la comunicación, en el primer semestre de 2027. El segundo sería un predictor relativo que use el retraso y la confianza de cada fuente, con probabilidades calibradas. La colaboración con tu compañero va en paralelo, como paper conjunto. El plan detallado está en la sección 12.

Las 10 conclusiones, una por cuestión (la lluvia de ideas tiene su propia sección, la 11):

1. **Usar predicciones sí merece la pena, pero hay tres formas.** Tus propias predicciones del frame anterior funcionan y son tendencia. Las de los demás agentes sirven para joint. Las que llegan por V2X mejoran poco solas; su valor está en ir acompañadas de confianza y edad del mensaje.
2. **Agent-centric es el más usado (24 de 62 papers), pero la familia relativa / query-centric le ha alcanzado (21) y en 2025 le adelanta (7 frente a 4).** En V2X-Seq, los 6 papers son relativos. Agent-centric no es el menos preciso: es el más caro. **Corrección:** V2X-RECT (nov 2025) ya llevó QCNet a V2X, en contra de lo que te dije.
3. **Joint no es raro (22 de 62 papers) y Waymo dejó en 2025 solo el reto joint, no el marginal.** En V2X solo lo hace I2XTraj. Fuera del paper 1, como ablación en el paper 2 y como capítulo "joint en la RSU" en el año 3.
4. **La dificultad de Kalman sigue siendo la forma estándar de medir el long-tail.** La selección de datos ha ido a otros criterios (TAROT, Den-TP). En V2X sirve para medir dónde ayuda de verdad la infraestructura. Ojo: no tienes ningún dataset V2I real descargado.
5. **Los papers de arquitectura no usan UniTraj; lo usan los de datos y evaluación. Y no hay nada parecido para V2X.** Ese hueco es tu paper 1.
6. **Los sensores crudos son raros (de 2 a 4 papers sobre 62) y caros.** La palanca grande es entrenar con pistas imperfectas (Valeo4Cast: mAPf de 43.3 a 63.0). **Colaboración con GaussianCaR: sí,** como "BEV de cámara + radar → predicción sin mapa HD", en paralelo y con la autoría pactada.
7. **Base para entrenar:** encoder relativo, propuesta → refinamiento, reutilizar predicciones pasadas, entrenar con pistas ruidosas y degradación V2X, y probabilidades calibradas. Partir de QCNet no es copiar, pero la aportación tiene que ir encima.

8. **Jev (TypeSafe AI)** no tiene arquitectura publicada. Su idea útil es la de probabilidades calibradas con un umbral para decidir cuándo actuar. Me equivoqué al tomarlo por JEPA.
9. **La calibración ya no es un hueco vacío en single-agent** (Evidential, SPARC, Wu et al. 2026). **En V2X sí lo es:** solo V2INet la toca. El regret, para más adelante.
10. **El benchmark V2X es publicable si trae preguntas:** protocolo único, calibración, robustez, coste y análisis por dificultad. Las cifras actuales no son comparables: el mismo V2X-Graph aparece con 1.05 y con 1.17 de minADE.

Lo primero, esta semana:

- [ ] Comprobar cómo descargar V2X-Seq-TFD desde España y bajar V2X-Traj.
- [ ] Montar en el bench V2X-Graph y V2INet, y reproducir su cifra en V2X-Seq.
- [ ] Escribir a tu compañero proponiendo la opción B y una reunión para pactar interfaz y autoría.

1. La innovación de cada paper y si merece la pena usar predicciones

Sí merece la pena, pero "usar predicciones" son tres cosas distintas y no valen lo mismo. Reutilizar tus propias predicciones del frame anterior es hoy una tendencia fuerte. Usar las predicciones de los demás agentes del mismo instante sirve sobre todo para predicción joint. Recibir predicciones por V2X da mejoras pequeñas, salvo que lleguen con su confianza y su retraso; ahí está tu hueco.

Etiquetas de fuente en todo el informe: **[Proyecto]** = tus PDFs y documentos; **[Repo]** = tu repositorio; **[Web]** = papers y páginas consultados entre el 4 y el 5 de noviembre de 2026.

1.1 Lo nuevo de verdad en cada paper (mi lectura) [Proyecto]

Paper	Su innovación, en pocas líneas	Lo que me llevaría a tu modelo
UniTraj	No es un modelo. Unifica 4 datasets en un formato y demuestra que la variedad de datos pesa más que la cantidad. Introduce la evaluación por dificultad de Kalman.	La evaluación por dificultad.

Paper	Su innovación, en pocas líneas	Lo que me llevaría a tu modelo
QCNet	Cada elemento vive en su propio marco y las relaciones van en un descriptor relativo, así se reutiliza lo ya calculado entre frames. Propone sin anchors y luego refina con anchors.	El encoder relativo y el esquema propuesta → refinamiento.
MTR	Queries de intención fijas (k-means de destinos) más una query dinámica que se mueve al destino predicho. Además predice el futuro denso de todos los vecinos para que el decoder sepa qué harán los demás.	Los puntos de intención y la predicción densa de vecinos.
TrajFlow	Genera todas las trayectorias de una vez con flow matching y entrena las probabilidades de los modos con una pérdida de ranking.	Entrenar la confianza de forma explícita.
SceneInformer	Predice a la vez lo que ve y si hay alguien en las zonas tapadas.	La oclusión como problema central, que es justo lo que V2X resuelve.
CMP	Primer pipeline que encadena percepción cooperativa, tracking y predicción, y agrega las predicciones de varios coches.	El módulo de agregación (tu propuesta de arreglo, brazos A y B).
GameFormer	Decoder por niveles: en cada nivel, cada agente responde a lo que los demás predijeron en el nivel anterior. Predice y planifica a la vez.	El razonamiento iterativo de interacción, si haces joint.
Wayformer	Estudia de forma sistemática cómo fusionar las entradas (temprana, tardía, jerárquica) con atención eficiente. Demuestra que una arquitectura simple basta.	Sus conclusiones de fusión, que se aplican a fusionar vistas V2X.
Co-MTP	Fusiona en dos tiempos: el pasado visto por coche e infraestructura, y el futuro (predicciones de la infraestructura y plan del AV).	Usar el futuro de otras fuentes, pero sin información privilegiada.

Paper	Su innovación, en pocas líneas	Lo que me llevaría a tu modelo
CoPAD	Limpia y fusiona las pistas de varias fuentes antes del modelo (Hungarian + Kalman), y usa un decoder con anchors.	La fusión temprana barata de pistas.
V2X-Graph	Grafo interpretable que asocia las trayectorias de distintas vistas. Publica el dataset V2X-Traj.	La asociación entre vistas dentro del modelo, y V2X-Traj.

1.2 Las tres formas de "usar predicciones"

Forma	Ejemplos	Qué dice la evidencia	¿Para tu modelo?
Tus propias predicciones del frame anterior (streaming)	RealMotion, HPNet, DONUT, SHARP	Mejoras pequeñas pero constantes. RealMotion sobre QCNet baja el $minFDE_6$ en AV2 val de 1.27 a 1.24 [Repo]. DONUT pasa de 1.874 a 1.807 de b-$minFDE_6$ en val y logra 1.79 en test, el mejor sin ensemble [Web]. SHARP, el primero de AV2 en 2026, es streaming [Web].	**Sí.** Es la tendencia 2024–2026.
Predicciones de los demás en el mismo instante	GameFormer (niveles), MTR (futuro denso), BeTop, JAM	Sirven sobre todo para joint. JAM, que primero propone en marginal y luego refina en joint, tiene el mejor minADE/minFDE del test interactivo de WOMD con 17.8 ms [Web].	Sí si haces joint; opcional en marginal.
Predicciones que te manda otro coche o la infraestructura (V2X)	CMP, Co-MTP, I2XTraj, Late Fusion	Resultados mixtos (detalle abajo).	**Sí, pero con confianza y retraso adjuntos.**

Lo que dice la evidencia sobre compartir predicciones por V2X [Web, salvo que se indique]:

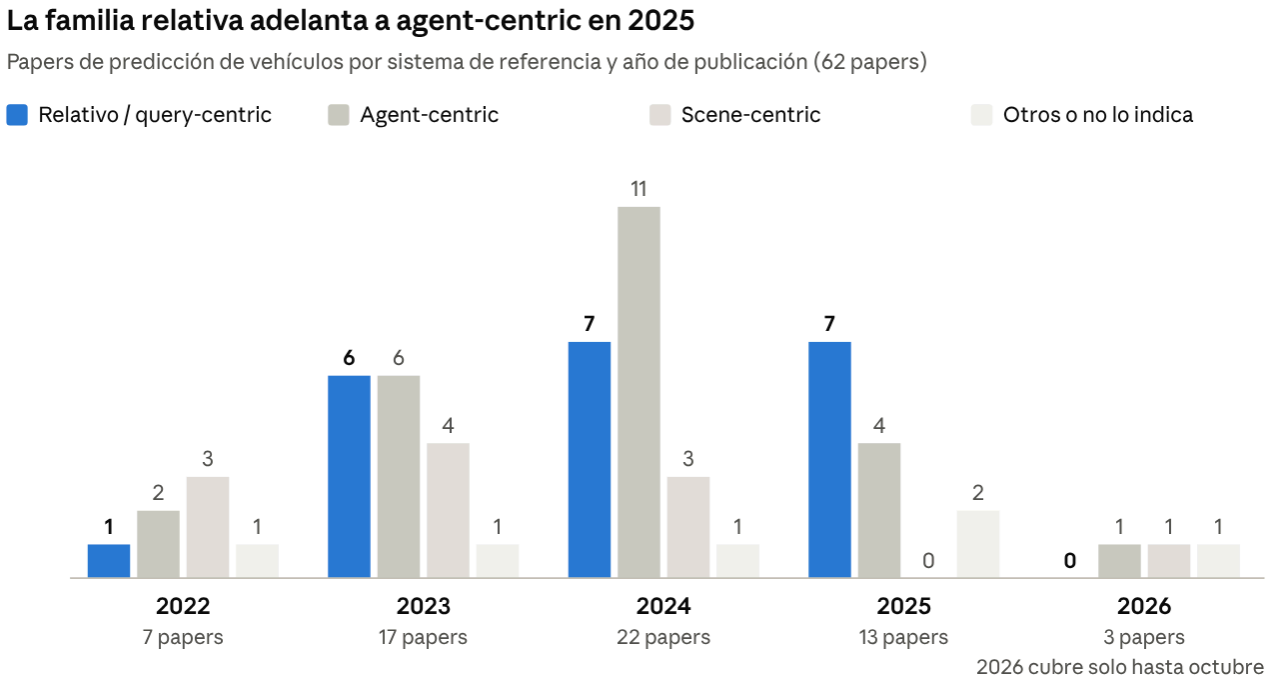
- **Late Fusion (abr 2026)** comparte trayectorias con su varianza y las fusiona con un proceso gaussiano. La mejora es pequeña: en OPV2V el MR baja de 21.97 % a 18.85 %, y en V2V4Real el éxito sube un 1.7 %. Los mensajes caben en 1,500 bytes a 10 Hz.
- **Co-P&P (Wan et al., ago 2026)** compara dónde fusionar. Fusionar a nivel de predicción rinde **peor** que fusionar a nivel de detección o de tracking.
- **V2XPnP (ICCV 2025)** llega a lo mismo: la fusión intermedia gana a la temprana, y la temprana a la tardía.
- **Co-MTP** sí gana mucho con el futuro (minADE de 0.91 a 0.76) [Proyecto]. Pero parte de esa mejora viene del plan del AV, que sale del ground truth.
- **I2XTraj (2025)** usa un esquema muy práctico. La infraestructura predice a todos y lo emite en un solo sentido, sin canal de vuelta, y tolera unos 400 ms de retraso.

Sobre las predicciones "poco sofisticadas". Que la predicción que llega sea simple importa menos que saber cuánto fiarse de ella. Late Fusion usa predictores sencillos (LSTM o Transformer) y aun así mejora, porque cada predicción viaja con su varianza. Por eso lo valioso para tu tesis es la confianza explícita que acompaña a la predicción, más que una predicción mejor.

Mi conclusión. No es una práctica en desuso: las tres formas siguen vivas en 2026. Para tu modelo: la primera sí desde el principio; la segunda cuando hagas joint; y la tercera es tu terreno de investigación, siempre como "predicción + confianza + edad del mensaje".

2. Agent-centric, scene-centric, query-centric y relativo: quién usa qué (2022–2026)

Agent-centric es el más usado en el total (24 de 62 papers, 39 %), pero la familia relativa / query-centric lo alcanza (21 de 62) y en 2025 lo adelanta (7 frente a 4). En V2X la situación es más extrema: los 6 papers que trabajan sobre V2X-Seq usan la familia relativa.



Clasificación propia de 62 papers 2022–2026, leída en cada paper · detalle en la pestaña «Clasificación de los 62 papers»

Cómo lo he contado. Partí del repositorio Awesome-Trajectory-Motion-Prediction-Papers que me pasaste (251 entradas, actualizado en julio de 2026). Me quedé con los papers que proponen un predictor de vehículos y quité peatones, pose humana, ataques, datasets y planificación pura. Le añadí los modelos importantes que faltaban en la lista (MTR++, QCNeXt, ModeSeq, HDGT, GoRela, SIMPL, EDA, MultiPath++…) y todos los papers V2X de predicción que encontré. Salen 62. La clasificación la leí en cada paper, buscando la frase donde dicen en qué marco ponen la escena; 15 vienen de tus PDFs y el resto los abrí en arXiv [Web]. Cuento cada paper en el año de su congreso o revista, o en el de arXiv si no tiene. La tabla completa, con la frase que justifica cada caso, está en la pestaña **«Clasificación de los 62 papers»**.

Las cuatro familias, en una línea cada una:

- **Agent-centric:** se copia la escena entera en el marco de cada agente objetivo. Una copia por objetivo.
- **Scene-centric:** un único marco para toda la escena (global, o centrado en el ego o en un agente focal).
- **Relativo (estilo HiVT):** cada agente en su marco local y las relaciones entre pares como posición y ángulo relativos.
- **Query-centric (QCNet y descendientes):** lo mismo que el relativo, pero añadiendo el tiempo a la relación, lo que permite reutilizar cálculos entre frames. En el gráfico van juntos porque son la misma idea.

2.1 Por qué agent-centric domina si es el peor para n agentes

No es el peor: es **el más caro, pero no el menos preciso**. Hay cuatro razones para su dominio, y un matiz al final:

1. **Precisión.** "Narrowing the coordinate-frame gap" (2022) lo midió directamente: agent-centric es más preciso, y scene-centric es hasta 15 veces más eficiente en escenas densas [Web].
2. **Los benchmarks premian a un solo agente.** AV2 evalúa un agente focal y WOMD hasta 8 objetivos. Repetir la escena por objetivo no penaliza en el leaderboard.
3. **Herencia de código.** Muchos modelos de 2024 descienden de MTR (EDA, CMP) o de Forecast-MAE (RealMotion, SHARP; DeMo toma piezas de ambos), que son agent-centric.
4. **Sencillez.** No hace falta diseñar codificaciones relativas. SceneMotion defiende además que aprende con menos datos [Web].
5. **El matiz: el coste ya tiene solución sin perder precisión.** GoRela mantiene el tiempo de su encoder casi constante al subir el número de agentes, mientras que repetir por agente cuesta unas 7 veces más con 40 agentes [Web]. ADAPT predice a todos en 11 ms frente a 64 ms de HiVT [Web].

En el top de AV2 hay empate. DeMo y SHARP son agent-centric; DONUT, ModeSeq y QCNet son query-centric. **La precisión no decide el paradigma; lo decide el coste cuando hay muchos agentes, y en V2X hay muchos.**

2.2 En V2X

Paper	Datos	Paradigma	Base de código
V2X-Graph (NeurIPS 2024)	V2X-Seq, V2X-Traj	Relativo	HiVT
V2INet (2024)	V2X-Seq	Relativo	HiVT
Co-MTP (ICRA 2025)	V2X-Seq	Relativo	Grafo heterogéneo propio
CoPAD (2025)	V2X-Seq	Relativo	Estilo HiVT
I2XTraj (2025)	V2X-Seq, SinD	Relativo	HPNet
V2X-RECT (nov 2025)	V2X-Seq, V2X-Traj	Query-centric	QCNet

Paper	Datos	Paradigma	Base de código
CMP (RA-L 2025)	OPV2V, V2V4Real	Agent-centric	MTR
V2XPnP (ICCV 2025)	V2XPnP-Seq	Agent-centric (desacoplado)	Propio
MSMA (2024)	CARLA	Scene-centric (centrado en el coche conectado)	Propio
Late Fusion (2026)	OPV2V, V2V4Real, DeepAccident	Marco global	LSTM o Transformer
CAMNet (2025)	AV2 + mensajes CAM	Posiciones relativas simples, sin mapa	VRNN

Lectura. Los 6 papers de V2X-Seq usan la familia relativa; ninguno de los 5 de OPV2V, V2V4Real o CARLA la usa. No es una ley de V2X: es herencia. El ecosistema de V2X-Seq viene de HiVT, y el de OPV2V viene del mundo de la percepción (OpenCOOD + MTR). Aun así, el relativo es el que mejor encaja con V2X: cada fuente llega en su propio sistema de coordenadas y con su propio retraso, y el relativo no necesita un marco común para cada objetivo.

Corrección a mis documentos anteriores. En el doc de respuestas y en el Word v2 escribí que nadie había llevado el query-centric de QCNet a V2X. **Es falso: V2X-RECT (arXiv, nov 2025) lo hace** [Web]. Reporta 0.53 / 0.80 / 0.09 de minADE / minFDE / MR en V2X-Seq, con 104 ms y 1.3 M de parámetros. No he encontrado su código y no he podido comprobar si su protocolo es comparable. Esto cambia tu estrategia (sección 7): ya no basta con "QCNet en V2X"; hay que aportar algo encima.

3. Joint multi-agent prediction: ¿es lo mejor y hay que dejarla fuera?

Joint no es "lo mejor" en general: es lo correcto cuando importa que las predicciones de varios agentes sean coherentes entre sí (cruces, incorporaciones, planificación). Tampoco es raro: 22 de los 62 papers la ofrecen. Mi recomendación: fuera del primer paper, como extensión medida en el segundo, y con la infraestructura como el sitio natural para hacerla.

3.1 Quién la usa

La usan 22 de los 62 papers [Web + Proyecto]: Scene Transformer, AutoBots, THOMAS, M2I, FJMP, MotionDiffuser, GameFormer, MotionLM, BiFF, ADAPT, TrafficBots, QCNeXt, MTR++, HPNet, SceneMotion, SMART, BeTop, DriveGPT, JAM, TrajFlow, SHARP e I2XTraj. Tu impresión de que "nadie la usa" viene de que tus 11 papers son casi todos marginales; solo GameFormer y TrajFlow reportan joint.

La señal más clara de hacia dónde va el campo: **en 2025 Waymo ya no convocó el reto de predicción marginal.** Mantuvo Interaction Prediction (joint), Sim Agents, Scenario Generation y uno nuevo de conducción end-to-end [Web].

3.2 ¿Es más cara?

Menos de lo que parece. El coste está sobre todo en cómo combinar los modos de varios agentes y en cómo evaluarlos, no en la red:

- **FJMP:** 10 ms por escena sin factorizar, 38 ms con su grafo disperso y 62 ms con el denso, en una V100 [Web].
- **JAM:** 17.8 ms con 12.2 M de parámetros [Web].
- **ADAPT:** predice a todos los agentes en 11 ms, frente a 64 ms de HiVT [Web].
- **Las métricas joint son más duras.** En peatones salen unas 2 veces peores que las marginales ("Joint Metrics Matter", ICCV 2023) [Web]. Un modelo puede parecer bueno en marginal y producir futuros que chocan entre sí.

3.3 En V2X

Solo I2XTraj hace joint: en V2X-Seq obtiene un minJointADE de 0.52 frente a 0.68 de HPNet [Web]. El protocolo oficial de V2X-Seq es marginal por agente, y por eso nadie más la reporta. Hay un argumento propio de V2X a favor: la infraestructura ve a todos los agentes del cruce, así que es el sitio natural para calcular una predicción conjunta y emitirla a los coches.

3.4 Decisión que te propongo

1. **Paper 1 (benchmark):** marginal, que es el protocolo de los datasets. Aun así, reporta una métrica de coherencia barata (tasa de solapamiento entre los modos más probables de cada agente). Enseña si los modelos V2X producen futuros incompatibles.
2. **Paper 2 (método):** marginal multi-agente en una sola pasada, gracias al encoder relativo. Joint como ablación: un refinamiento joint ligero tipo JAM o GameFormer encima.
3. **Tesis (año 3):** "joint en la RSU" como capítulo, si los resultados anteriores lo justifican.

4. La dificultad de Kalman y la elección de datos relevantes

Sí se sigue usando, aunque no siempre con ese nombre. Es la forma estándar de medir el long-tail, la cola de casos difíciles. La selección de datos, en cambio, ya ha pasado a otros criterios. Para tu tesis su mejor uso es medir en qué casos ayuda la infraestructura.

4.1 De dónde viene y quién la usa

- **Origen.** Makansi et al. (ICCV 2021) definen la dificultad de una muestra como el error de un filtro de Kalman que extrapola su pasado [Web]. Si un Kalman la acierta, es fácil; si falla mucho, es una maniobra. UniTraj la reutiliza para su evaluación por dificultad [Proyecto].
- **Línea long-tail.** FEND (CVPR 2023), AMEND, TrACT y CDKFormer (2025) se evalúan en el subconjunto más difícil [Web]. Un trabajo de ITSC 2025 lo resume: los anteriores "ordenaban la dificultad con un filtro de Kalman o con un modelo base" [Web]. Ese mismo trabajo muestra por qué importa: en el 10 % más difícil de nuScenes, un ensemble baja el error un 13 % respecto a MTR; en el total, mucho menos.
- **Selección de datos.** Ha ido por otro camino, sin Kalman:
  - **TAROT (ICML 2025),** sobre UniTraj, elige el 29.8 % de WOMD + AV2 + nuPlan y entrena mejor que con todo [Web]. Wayformer con esos datos logra 0.92 de minADE_5 en nuScenes, frente a 0.94 con todo.
  - **Den-TP (CVPR 2026)** agrupa por densidad, es decir, por el número de agentes en la escena. Con el 50 % de AV1, HiVT logra 0.706 / 1.074 de minADE / minFDE, frente a 0.695 / 1.037 con todo y 0.750 / 1.175 con un 50 % al azar [Web]. Con HPNet ahorra casi un 45 % del coste de entrenamiento.

4.2 Cómo te sirve en V2X

Una pregunta barata y publicable dentro del primer paper: **¿la infraestructura ayuda más en los casos difíciles?** Separa V2X-Seq en tramos por dificultad de Kalman y, aparte, en agentes ocluidos o no ocluidos para el coche. Mide la mejora de cooperar en cada tramo. Si la mejora se concentra en el 10 % más difícil, el valor real de V2X queda escondido en la media de minADE, y ese es un hallazgo.

4.3 ¿Es WOMD el mejor dataset?

Para predicción de un solo vehículo sí: es el más grande, tiene 8 s de horizonte y muchas interacciones [Proyecto]. Para una tesis V2X el mapa es otro [Repo `RECENT_V2X_LITERATURE.md` + Web]:

Dataset	Tipo	Qué trae para predicción	¿Lo tienes en `/raid` ?
V2X-Seq (TFD)	Real, coche + infraestructura	51,146 escenarios de 10 s a 10 Hz, 5 s → 5 s	**No.** La web dice que se descarga sin límite desde China continental; desde España hay que comprobar el acceso.
V2X-Traj	Real, 2 coches + infraestructura	10,102 escenarios en 28 cruces, 4 s → 4 s	No (el repo de V2X-Graph lo enlaza en Google Drive)
V2XPnP-Seq	Real, V2V + V2I + I2I	~100 escenarios en 24 cruces, sensores + trayectorias	No
UrbanIng-V2X (NeurIPS 2025)	Real, 2 coches + hasta 3 postes	3 cruces de Ingolstadt; sobre todo percepción	No
CAMASA (2026)	Real, mensajes V2X (CAM)	Trayectorias reconstruidas de 40 M de mensajes	No
OPV2V	Simulado (CARLA), V2V · DESCARTADO: solo usamos datos reales	El que usa CMP	**Sí** (197 GB)
V2V4Real	Real, 2 coches	El que usa CMP	**Sí** (41 GB)
V2X-Radar (NeurIPS 2025)	Real, radar 4D en coche e infraestructura	Solo detección, sin trayectorias	No

Lo urgente: tienes 647 GB de WOMD descargados (y tres repos preprocesados sobre él), pero ningún dataset V2I real. El primer paso práctico del nuevo plan es conseguir V2X-Seq-TFD y V2X-Traj.

Decisión (9 nov 2026): solo datasets reales. OPV2V y cualquier dataset simulado (CARLA, el sintético de Pretraining-on-Synthetic) quedan descartados y se pueden borrar del ordenador. V2V4Real se queda: es real.

5. ¿Usan UniTraj los papers recientes?

Los papers de arquitectura no lo usan; lo usan los de datos, generalización y evaluación. Y no soporta V2X.

5.1 Evidencia

- **Ninguno de los modelos punteros de 2024–2026 de mi tabla se entrena en UniTraj** [Web]. DeMo, RealMotion, SMART, ModeSeq, DONUT y SHARP se entrenan con el código de su predecesor y el devkit oficial de cada dataset.
- **Según Semantic Scholar, 78 papers citan UniTraj** [Web]. Los que de verdad lo usan como plataforma son de otro tipo:
  - TAROT (ICML 2025), para seleccionar datos.
  - "Closing the Loop" (2025), que conecta Autobot, Wayformer y MTR a un planificador en bucle cerrado.
  - Varios trabajos de generalización entre datasets.
- **Muchos solo lo citan.** ControlledShifts (2026), que estudia robustez en WOMD, cita UniTraj solo por sus métricas y no se construye sobre él [Web].
- **El repo sigue vivo pero crece en otra dirección** [Web]: TAROT en diciembre de 2024, SMART en mayo de 2025, Forecast-MAE y EMP en septiembre de 2025. Tiene 490 estrellas, sigue con WOMD, nuPlan, nuScenes y AV2, y no tiene nada de V2X.

5.2 Por qué no lo usan

1. **Los leaderboards exigen el protocolo oficial.** El config por defecto de UniTraj usa 2.1 s de pasado y 6 s de futuro para todos los datasets, que no es el de WOMD ni el de AV2 [Proyecto].
2. **Es agent-centric por diseño.** Hace una copia de la escena por agente objetivo. Los modelos relativos o query-centric no encajan sin reescribir su carga de datos.
3. **Cada modelo nuevo nace del código de su padre.** QCNet da lugar a DONUT y ModeSeq; Forecast-MAE da lugar a RealMotion y SHARP.
4. **ScenarioNet unifica a costa de perder detalle propio de cada dataset.** Por defecto enmascara la altura y el tamaño de los agentes [Proyecto].
5. **Licencia AGPLv3** [Repo `REPO_ASSESSMENT.md`]. Obliga a publicar como código abierto todo lo que se construya encima.

5.3 Qué significa para ti

UniTraj sirve para experimentos de generalización entre datasets de un solo vehículo. **Para V2X no existe su equivalente, y construirlo es precisamente el paper de benchmark de la sección 10.** Ese hueco es una oportunidad: "el UniTraj de V2X" con protocolo único,

robustez y calibración.

6. Sensores crudos (LiDAR, cámara) y la colaboración con tu compañero

Muy pocos usan sensores crudos: 2 de los 62 papers del recuento (CMP y V2XPnP), o 4 de 64 (6 %) si sumo MoST y MGTR, que están en la lista Awesome. Añadirlos mejora algo (en torno a un 6 % en mAP en WOMD), pero es muy caro, y un pipeline modular bien entrenado sigue ganando. La colaboración con tu compañero tiene sentido si se plantea como "BEV de cámara + radar → predicción" y no como un paper de percepción.

6.1 Qué consiguen los que usan sensores [Web, salvo que se indique]

Trabajo	Sensores	Qué hace	Resultado clave	Coste
MoST (CVPR 2024)	Cámara + LiDAR	Añade unos cientos de tokens de sensor a Wayformer en WOMD	mAP 0.3995 → 0.4230 (+5.9 %), minFDE 1.231 → 1.136 (−7.8 %); cámara sola ya da casi todo	64 núcleos TPUv4, 500k pasos
MGTR (ICRA 2024)	Rasgos de LiDAR + vectores	Fue 1.º en el leaderboard de WOMD en su momento	No publica la mejora atribuible al LiDAR	—
WOMD-LiDAR (2023–24)	LiDAR	Añade LiDAR a más de 100k escenas de WOMD	Dice que mejora, sin cifras en el resumen	—
Valeo4Cast (ECCVW 2024)	Cámaras → detección → tracking → MTR (modular)	Gana el reto end-to-end de AV2 con 63.82 mAPf	**Ajustar MTR con detecciones reales sube el mAPf de 43.3 a 63.0**	Modular, cada pieza por separado
UniAD (CVPR 2023)	Cámaras	Pila completa	—	30–50 GB por GPU solo la etapa 1 [Repo]

Trabajo	Sensores	Qué hace	Resultado clave	Coste
SpaRC-AD (ICCVW 2025)	Cámara + radar	End-to-end con velocidad Doppler	−4 % de error de movimiento frente a solo visión	—
CMP (RA-L 2025)	LiDAR cooperativo	Percepción cooperativa + tracking + MTR	Ver tus fichas [Proyecto]	Pesado
V2XPnP (ICCV 2025)	LiDAR cooperativo	Percepción y predicción juntas	ADE 1.35 frente a 1.87 sin cooperar	Mensaje comprimido 32×
UniV2X (AAAI 2025)	Cámaras coche + infraestructura	End-to-end orientado a planificar	Colisiones 0.89 % → 0.34 %	$8.1{\cdot}10^5$ bps frente a $8.2{\cdot}10^7$
Co-P&P (ago 2026)	LiDAR comprimido	Compara dónde fusionar	Fusionar predicciones es lo peor; un códec neuronal reduce el ancho de banda 34×	—

Lectura. Los sensores dan información que las pistas pierden: forma, señales e intención visual. Pero la palanca más grande que he visto es **entrenar el predictor con pistas imperfectas**: el salto de 43.3 a 63.0 de Valeo4Cast. Para una tesis sin percepción, la conclusión práctica es simular errores de tracking (IDs cambiados, huecos, ruido) o usar salidas reales de un detector. No hace falta procesar sensores.

6.2 El paper de tu compañero: GaussianCaR (arXiv 2602.08784)

Qué es [Web]:

- **Autores:** Montiel-Marín, Antunes-García, Sánchez-García, Llamazares, Holger Caesar y Bergasa (Universidad de Alcalá y TU Delft), febrero de 2026.
- **Qué hace:** proyecta cámaras y radar a una vista de pájaro (BEV) común mediante Gaussian Splatting. Saca la segmentación de vehículos (57.3 IoU), carretera (82.9) y líneas de carril (50.1) en nuScenes.
- **Velocidad:** 3.2 veces más rápido que BEVCar, con 75.6 ms en una RTX 4090. Se entrenó en 4 A100.
- **Límite:** solo segmenta el instante actual. No hace tracking ni predice el futuro, y no menciona V2X.

Mi opinión: sí tiene sentido, con condiciones.

A favor:

- **Sois complementarios:** ellos aportan la percepción y tú la predicción.
- **Holger Caesar es coautor.** Creó nuScenes, y eso da peso al paper.
- **El radar mide velocidad directamente** (Doppler), que es justo lo que un predictor necesita.
- **El radar es habitual en las unidades de infraestructura**, así que es un puente natural a V2X.
- **Las gaussianas encajan bien en V2X.** Son primitivas 3D que se pasan de un marco a otro con una rotación y una traslación, sin remuestrear una rejilla. Un trabajo de AAAI 2026 comparte gaussianas entre agentes para ocupación con el 34.6 % del volumen de comunicación [Web].

En contra:

- No es V2X.
- Un primer paper así tira hacia percepción.
- Ellos entrenan en 4 A100 y tú tienes una 3090.
- El hueco end-to-end está concurrido: UniAD, SparseDrive y ya hay radar + cámara con predicción (SpaRC-AD).

Opción	Qué sería	Encaje con tu tesis	Riesgo
A. Ocupación futura en BEV	Añadir tiempo y una cabeza de futuro a GaussianCaR (estilo FIERY)	Bajo: es su paper con tu ayuda	Bajo
B. BEV de cámara + radar como mapa y contexto de un predictor vectorial	Tu predictor atiende directamente a sus rasgos BEV en vez de a un mapa HD. Precedente: con solo cámara, atender al BEV en vez de al mapa vectorizado da hasta un 29 % más de precisión y un 73 % más de velocidad (Gu et al., ECCV 2024) [Web]	**Medio:** predicción sin mapa HD, que en V2X también falta a menudo	Medio

Opción	Qué sería	Encaje con tu tesis	Riesgo
C. Gaussianas de cámara + radar compartidas por V2X → predicción	La infraestructura envía gaussianas; el coche predice	Alto	Alto: V2X-Radar no tiene trayectorias anotadas

Mi recomendación: la opción B como paper conjunto en 2027, diseñada para crecer hacia la C en tu tesis. No la haría tu primer paper de primer autor; ese debería ser V2X. Cómo lo haría:

1. **Acordad la interfaz.** Ellos exportan los rasgos BEV o las gaussianas por frame en nuScenes; tú construyes el predictor que los consume.
2. **Pactad la autoría por escrito antes de empezar.**
3. **Baselines:**
   - predictor con mapa HD (cota superior);
   - mapa online (MapTR) + predictor;
   - BEV de solo cámara (Gu et al.);
   - el vuestro, con radar.
4. **Métricas:** minADE, minFDE, MR y latencia.
5. **Destino:** ITSC 2027 o ICRA 2028.
6. **Pregunta clave del paper:** ¿cuánto aporta el radar a la predicción cuando no hay mapa HD?

7. Qué tener en cuenta cuando entrenemos

Sí: un encoder relativo / query-centric, un decoder que propone y luego refina con anchors, y reutilizar predicciones pasadas es la base que mejor encaja con V2X. Partir de QCNet no es copiar. Pero como V2X-RECT ya llevó QCNet a V2X, tu aportación tiene que estar en lo que añades encima: retraso, confianza y calibración.

7.1 Sobre "copiarte de QCNet"

Construir sobre un backbone publicado es la norma, no la excepción [Web]:

- ModeSeq (CVPR 2025) y DONUT (ICCV 2025) usan el encoder de QCNet.
- V2X-RECT (2025) y Recover to Predict (CVPR 2026) parten de QCNet.
- SmartRefine (CVPR 2024) se monta encima de cinco backbones distintos.

Lo que se publica es la pregunta que respondes y el módulo que la responde, con QCNet citado como base. Tiene además licencia Apache-2.0 [Repo].

7.2 Lista de decisiones para el entrenamiento

#	Decisión	Mi recomendación	Evidencia	Prioridad
1	Sistema de referencia	Relativo / query-centric, todos los agentes en una sola pasada	GoRela, SIMPL y ADAPT: el coste no crece con los agentes; encaja con varias fuentes (sección 2) [Web]	Alta
2	**Tiempo real de cada observación**	Que cada dato V2X entre con el instante en que se midió, no con el del frame actual. Así el retraso de un mensaje es solo otra posición temporal en el descriptor relativo, sin módulo de compensación aparte	QCNet ya codifica el tiempo relativo [Proyecto]. No he visto ningún paper V2X que lo use así, pero no es una búsqueda exhaustiva	**Alta (idea propia)**
3	Decoder	Propuesta sin anchors → refinamiento con anchors; o puntos de intención por k-means	QCNet: b-minFDE$_6$ 2.10 → 2.02 con recurrencia → 1.90 con refinamiento. MTR: k-means 0.3437 de mAP frente a rejilla 0.3178. CoPAD: 2 anchors por modo es lo mejor [Proyecto]	Alta
4	Pérdida de modos	Winner-take-all + clasificación como base; probar la versión con recocido (aWTA). Entrenar con los K modos que vas a evaluar (6)	aWTA en MTR, AV2 val: minFDE 1.68 → 1.46 y MR 0.30 → 0.19, y un 20 % menos de tiempo de entrenamiento [Web]	Media

#	Decisión	Mi recomendación	Evidencia	Prioridad
5	**Probabilidades fiables**	Fine-tuning EM de un paso o una pérdida de ranking para que la probabilidad de cada modo signifique algo	Wu et al. (2026): winner-take-all se comporta como k-means y trocea cada comportamiento en varios modos con probabilidad baja; el fine-tuning EM baja el NLL de Wayformer un 59 % en nuScenes [Web]. TrajFlow mejora el mAP con su ranking [Proyecto]	**Alta para tu tesis**
6	Distribución de salida	Laplace por defecto (HiVT, QCNet, V2X-Graph, CoPAD); Gauss si quieres NLL comparable con MTR	No he encontrado una comparación limpia que dé un ganador claro; Laplace es más robusta a errores grandes	Baja
7	Predicciones pasadas (streaming)	Reutilizar las del frame anterior	RealMotion, DONUT, SHARP (sección 1)	Media (paper 2)
8	**Entrenar con pistas imperfectas**	Meter IDs cambiados, huecos y ruido en el entrenamiento, o usar pistas de un tracker real	Valeo4Cast: mAPf 43.3 → 63.0 al ajustar con detecciones. V2X-RECT dedica un módulo a corregir IDs [Web]	Alta
9	Aumentación de degradación V2X	Retrasos de 0 a 1.5 s, pérdidas del 10–50 % y ruido de posición durante el entrenamiento	MSMA retrasa de 1 a 15 frames; V2X-Graph prueba 0–200 ms y 10–50 % de pérdidas [Web + Proyecto]	Alta

#	Decisión	Mi recomendación	Evidencia	Prioridad
10	Datos	Preentrenar en AV2 o WOMD (ya los tienes) y ajustar en V2X	Un estudio de Bosch (2025): preentrenar en AV2 y ajustar en su dataset alemán mantiene el resultado en casa (0.70 frente a 0.69) y mejora mucho en AV2 (0.82 frente a 0.99) [Web]	Media
11	Tamaño	Modelos de 1 a 5 M de parámetros, que caben de sobra en tu 3090	HiVT 2.6 M, SIMPL 1.8 M y V2X-RECT 1.3 M, frente a MTR 65 M [Web + Repo]	Alta
12	Métricas desde el día 1	minADE, minFDE y MR + brier-minFDE + NLL o ECE + latencia, por tramo de dificultad	Secciones 4 y 9	Alta

7.3 Lo que no haría todavía

- **Modelos generativos (difusión o flow matching) o autoregresivos por tokens (MotionLM, SMART).** Son la frontera en simulación, pero cuestan más y no son tu pregunta.
- **Ensembles para subir en el leaderboard.** No responden a ninguna pregunta de la tesis.

8. Jev, de TypeSafe AI

Corrección primero: en el doc de respuestas interpreté "jev" como JEPA y me equivoqué. Jev salió en septiembre de 2026, después de la fecha hasta la que llega mi conocimiento, y no lo conocía. **Conclusión: no hay arquitectura que copiar (no es pública), pero sí una idea que encaja con tu tesis: probabilidades calibradas y un umbral que decide cuándo actuar y cuándo no fiarse.**

8.1 Qué es [Web]

- **Qué se le pide.** Es un modelo "System One" (la idea de pensamiento rápido de Kahneman) para decisiones rápidas dentro de software. Recibe una pregunta estructurada con las opciones permitidas. Devuelve una decisión tipada con su

probabilidad y su confianza.

- **Cómo genera.** Produce todos los campos de la respuesta en una sola pasada, no token a token como un LLM.
- **Cómo se entrena.** Con "Reinforcement Learning for Calibrated Decisions" (RLCD): buscan que la probabilidad que da coincida con lo a menudo que acierta.
- **Cifras de la propia empresa.** 0.114 s frente a 8.566 s de un LLM, y "193.6× más rápido, 444.6× más barato". Cuesta 42 $ por cada mil millones de tokens de entrada. El desarrollador fija un umbral: por encima, Jev actúa solo; por debajo, lo pasa a una persona.
- **Quién está detrás.** Lo fundó Diogo Almeida, ex-OpenAI, con una ronda de 40 M$. El 6 de octubre de 2026 OpenAI sacó su "Decisions API" como respuesta.
- **Lo que no se sabe.** No hay paper ni pesos, y la arquitectura no está publicada. Ninguna medida de calibración (ECE, Brier) está verificada de forma independiente. Las demos de conducción son en simulador.

8.2 Qué te puedes llevar

1. **La confianza como producto.** El valor de un predictor no está solo en acertar con la mejor de 6 trayectorias. También está en que su probabilidad sea creíble. En V2X eso decide cuándo fiarse de lo que manda la infraestructura y cuándo de lo propio. Es tu sección 9.
2. **Entrenar para la calibración, no solo para la precisión.** El equivalente a RLCD en predicción son las pérdidas que premian probabilidades honestas: NLL, Brier, el ranking de TrajFlow o el fine-tuning EM de Wu et al. (sección 7, fila 5).
3. **Decidir cuándo no actuar.** Si la confianza baja de un umbral, se cae a un plan conservador o se pide ayuda a la infraestructura. En predicción se llama predicción selectiva o conformal, y V2INet ya lo hace en V2X-Seq [Web].
4. **Salida de una sola pasada.** Ya es la norma en MTR y QCNet, que sacan los K modos a la vez. Los modelos por tokens como MotionLM o SMART van en dirección contraria y son más lentos. Para tiempo real en V2X, una sola pasada es lo correcto.

Veredicto: úsalo como inspiración para contar el capítulo de calibración ("predictores que saben cuándo no saben"). Técnicamente no hay nada que reutilizar.

9. Segunda vuelta a la calibración y al regret: ¿sigue siendo tuyo ese hueco?

Hay que matizar lo que te dije. "Nadie mide la calibración" ya no es cierto en predicción de un solo vehículo: en 2025–2026 han salido varios trabajos. **Lo que sigue libre es la calibración en V2X**: si cooperar mejora o empeora la fiabilidad de las probabilidades,

cómo se degrada con el retraso, y cómo usar esa confianza para fusionar fuentes. El regret lo dejaría para más adelante.

9.1 Qué existe ya [Web]

Trabajo	Qué aporta	Dato clave
Evidential (2025)	Incertidumbre de posición y de modo en una sola pasada	ECE en AV2: 0.05 con HiVT, 0.01 con su cabeza evidencial
Wu et al. (2026)	Explican por qué las probabilidades de los modos salen poco informativas: winner-take-all se comporta como k-means	Fine-tuning EM: NLL de Wayformer −59 % en nuScenes
SPARC (ago 2026)	Capa bayesiana + conformal que da tubos de confianza del 95 % sin muestrear	Primero en NLL en sus pruebas
Regret (CoRL 2024)	Mide el error según el daño que causa al planificador	Necesita un planificador
Closing the Loop (2025)	Lleva los predictores a bucle cerrado con un planificador	MTR-Mini (9.3 M) supera a MTR (65 M) en bucle cerrado: 0.850 frente a 0.818, aunque es 5.º en bucle abierto
ControlledShifts (2026)	Robustez bajo cambios de distribución en WOMD	Los rankings de calidad y de estabilidad salen casi al revés; no mide calibración

9.2 Qué hay en V2X

- **V2INet** envuelve el predictor con predicción conformal en V2X-Seq. Sin calibrar cubre el 78 % frente al 90 % objetivo [Repo `MODELS_OVERVIEW.md`].
- **Late Fusion (2026)** comparte la varianza de cada predicción y la usa para fusionar [Web].
- **Nadie más.** Co-MTP, CoPAD, V2X-Graph, V2X-RECT e I2XTraj solo reportan minADE, minFDE y MR [Proyecto + Web].

9.3 El hueco, reformulado

Tres preguntas que, hasta donde he podido buscar, nadie ha respondido:

1. **¿Están calibrados los predictores V2X?** Y si se mide brier-minFDE o NLL, ¿cambia el ranking que da minADE?
2. **¿La infraestructura mejora la calibración además de la precisión?** ¿En qué casos: los difíciles, los ocluidos?
3. **Con retraso y pérdidas de mensajes, ¿se degrada antes la calibración que el minADE?** Si es así, el modelo se vuelve "seguro de sí mismo y equivocado" justo cuando la comunicación falla, que es lo peligroso.

Y una cuarta, de método: **usar la confianza calibrada como peso de fusión.** Eso conecta con el brazo B de tu propuesta para CMP y responde a la crítica de Late Fusion.

9.4 ¿Y el regret?

Necesita un planificador, y V2X-Seq no lo trae. Ponerlo a mano (por ejemplo, un planificador simple sobre las predicciones, al estilo de "Closing the Loop") es un proyecto en sí. Lo dejaría para el año 3 o para un paper de bucle cerrado. Las tres preguntas de arriba se pueden responder ya con las métricas de bucle abierto.

10. ¿Es publicable re-entrenar todo V2X como benchmark?

Sí, si es un benchmark con preguntas y no una tabla re-entrenada. Necesita un protocolo único, robustez, calibración, coste y código abierto. **Es el primer paper de primer autor que te recomiendo:** el riesgo es bajo, cabe en tu GPU y deja la base de todo lo demás.

10.1 Por qué hace falta

El mismo modelo aparece con cifras distintas según quién lo cuente [Proyecto + Web]:

- **V2X-Graph** da 1.05 / 1.79 / 0.25 en su paper de NeurIPS. Co-MTP, CoPAD y V2X-RECT le atribuyen 1.17 / 2.03 / 0.29.
- **HiVT** aparece entre 1.12 y 1.29 de minADE en el mismo dataset.
- **Co-MTP** usa otro protocolo (3 s → 5 s a 5 Hz) y el futuro real del AV como "plan".
- **V2X-RECT** dice 0.53 / 0.80 / 0.09, casi la mitad que todos los demás, y sin código para comprobarlo.

Hoy nadie puede decir qué método V2X es mejor.

10.2 Precedentes de que este tipo de paper se publica [Web + Proyecto]

- **UniTraj (ECCV 2024)** y **"What Truly Matters in Trajectory Prediction" (NeurIPS 2023)** son análisis y frameworks, no modelos.

- **STEP (IEEE Open Journal of ITS, 2025)** y **"Toward Unified Practices…" (IV 2025)** son plataformas y prácticas de benchmarking (estos dos los conozco solo por el título, en la lista de citas de UniTraj).
- **V2XPnP (ICCV 2025)** comparó 11 modelos de fusión en su propio dataset. Ojo, que se solapa en parte contigo: es end-to-end desde LiDAR y en su dataset. **Tu diferencia:** predicción a nivel de trayectorias, en V2X-Seq y V2X-Traj, con robustez y calibración.

10.3 Qué tendría que tener para no ser "solo un re-run"

Pieza	Contenido
Datasets	V2X-Seq-TFD y V2X-Traj; V2V4Real como extra para V2V (real, ya lo tienes). OPV2V descartado por ser simulado
Métodos con código	HiVT (base), V2X-Graph (código y checkpoint), V2INet (código), Co-MTP (código en GitHub, último commit en marzo de 2025), la predicción de CMP y un QCNet adaptado por ti. CoPAD, V2X-RECT e I2XTraj sin código encontrado: se citan, se marca y se explica por qué no están
Un protocolo	Mismo split, horizonte, frecuencia y entradas. Sin información privilegiada (nada de futuro real del AV). Varias semillas
Ejes de análisis	Precisión; calibración (brier-minFDE, NLL); robustez (retraso 0–500 ms, pérdidas 10–50 %, ruido); coste (ms, parámetros, bytes por mensaje); por tramos de dificultad de Kalman y de oclusión
Entregable	Configs, Docker (tu bench) y una tabla de referencia que otros puedan reutilizar

10.4 Riesgos

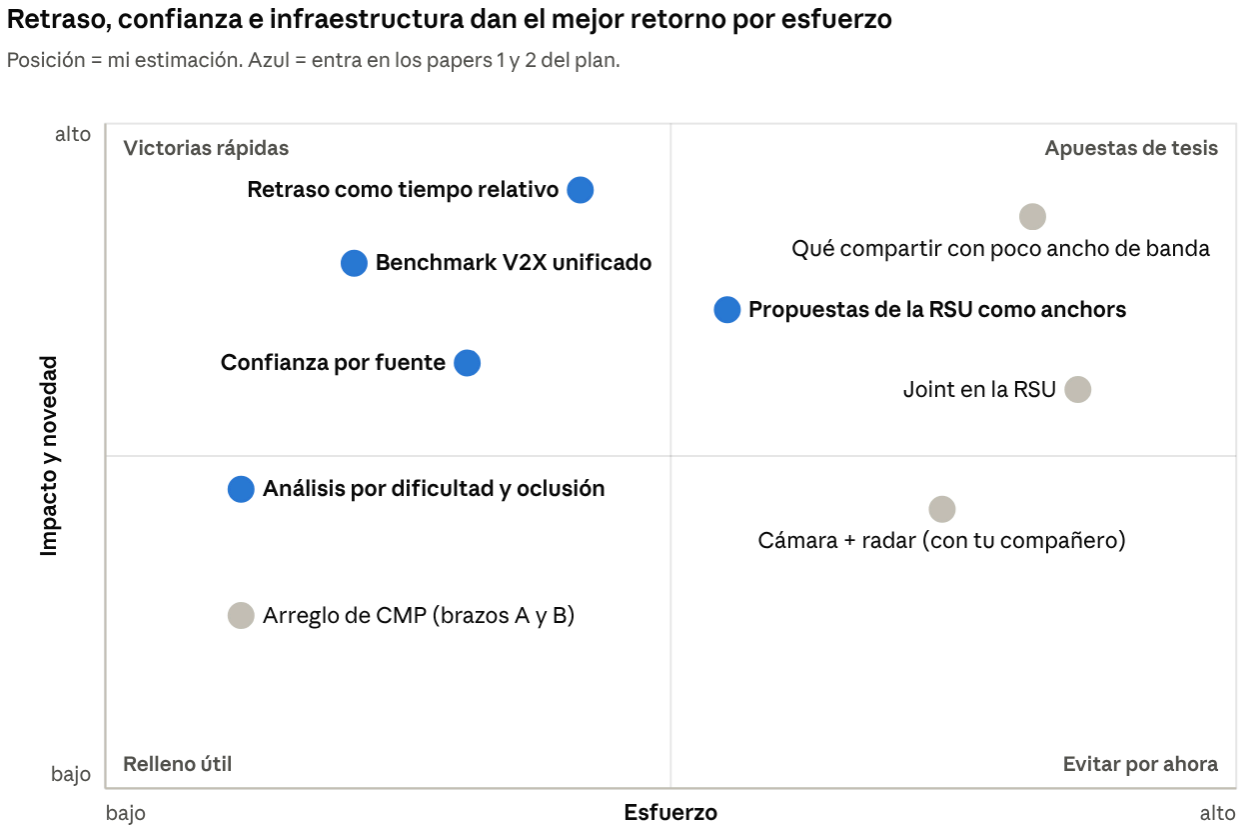
- **Acceso a V2X-Seq.** La web dice que se descarga sin límite desde China continental; desde España puede requerir solicitud. Es lo primero que hay que comprobar.
- **Cómputo.** Mi estimación gruesa: 5 o 6 métodos × 2 datasets × 3 semillas son unos 30–40 entrenamientos. Con modelos de 1–5 M de parámetros en unos 50k escenarios, eso es del orden de 1 a 2 meses de una sola 3090. Es viable, pero hay que empezar pronto.

- **Revisores que lo vean como "solo reproducir".** Se mitiga con las preguntas de la sección 9.3 y del análisis por dificultad (4.2): que el paper diga algo nuevo, por ejemplo que el ranking cambia al medir calibración o retraso.
- **Que alguien lo publique antes.** No he encontrado un benchmark unificado de predicción V2X a nivel de trayectorias, pero el campo se mueve rápido. Conviene sacar una versión en arXiv pronto.

Destino: IEEE T-ITS o RA-L como revista (sin fecha límite), o IV 2028 como conferencia. ITSC 2027 sería muy apretado. NeurIPS Datasets & Benchmarks solo si llega muy completo.

11. Lluvia de ideas inicial

Tienes razón en que habrá que innovar, pero no hace falta inventar una arquitectura entera. Las ideas con más retorno salen de tres cosas que V2X tiene y la predicción de un solo coche no: el retraso de los mensajes, la fiabilidad de cada fuente y una infraestructura que lo ve todo. Aquí van las 9 que yo pondría sobre la mesa para la primera sesión.



Lluvia de ideas inicial · 9 ideas situadas por esfuerzo e impacto (mi estimación)

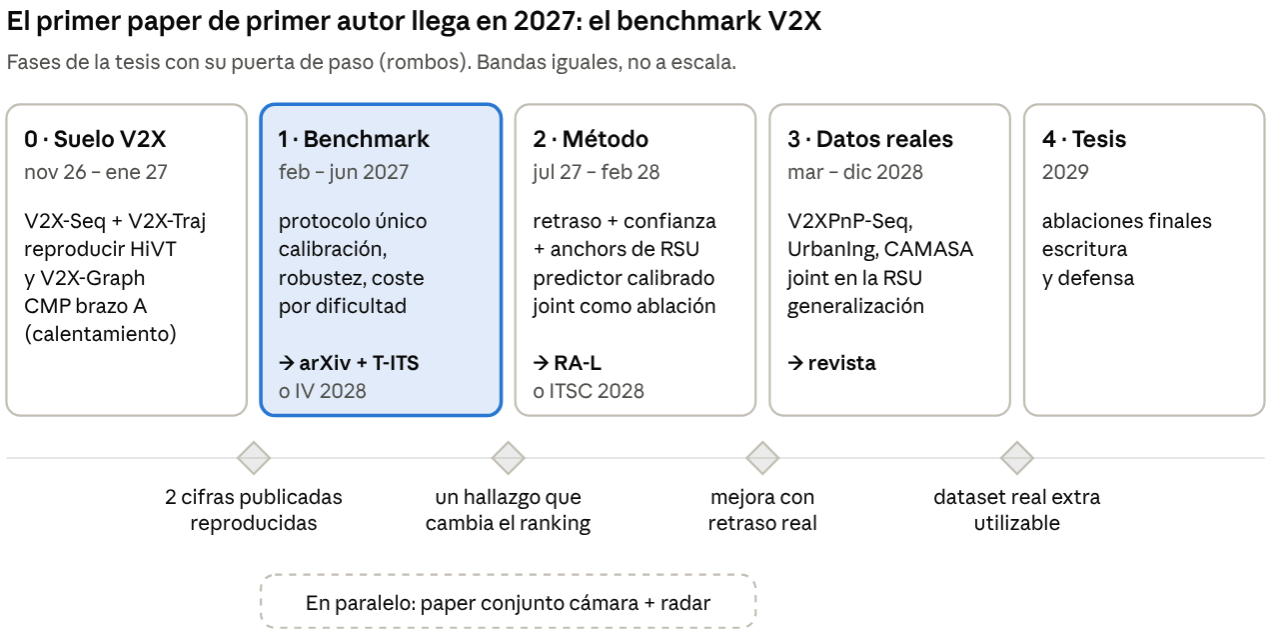
Idea	Qué es	Por qué es nueva	Riesgo principal
Retraso como tiempo relativo	Encoder query-centric donde cada observación V2X entra con su instante real. Un mensaje con 300 ms de retraso es simplemente un dato 300 ms más viejo, y la red aprende a usarlo.	Los papers V2X compensan el retraso con módulos aparte (interpolación en V2X-Graph, extrapolación en UniV2X) o lo ignoran.	Que la mejora sobre una simple interpolación sea pequeña.
Confianza por fuente	Un "token de fiabilidad" por fuente (edad del mensaje, score de detección, covarianza del tracker) que entra en la atención. Generaliza el brazo B de tu propuesta para CMP.	Tu búsqueda de septiembre no encontró a nadie haciéndolo en la entrada del predictor [Repo].	Definir bien qué es "confianza" (lo apunta tu propia propuesta).
Propuestas de la RSU como anchors	La infraestructura emite K trayectorias calibradas en un solo sentido, con pocos bytes. El coche las usa como anchors en su etapa de refinamiento, igual que QCNet usa sus propias propuestas.	Une el esquema de I2XTraj (emitir) con el de QCNet (refinar); no lo he visto junto.	Depende de que las propuestas de la RSU sean buenas.
Benchmark V2X unificado	Sección 10.	No existe para predicción a nivel de trayectorias.	Acceso a datos y cómputo.
Análisis por dificultad y oclusión	Sección 4.2: dónde ayuda de verdad la cooperación.	Nadie lo ha medido en V2X.	Ninguno serio; va dentro del paper 1.
Qué compartir con poco ancho de banda	Elegir qué agentes y qué modos enviar según cuánto mejoran la predicción del receptor, el equivalente de Where2comm para predicción.	La literatura de presupuesto de comunicación es casi toda de percepción.	Necesita simular la red; es más grande.
Joint en la RSU	La infraestructura calcula futuros conjuntos coherentes y los emite.	Solo I2XTraj hace joint en V2X.	Grande; mejor como capítulo del año 3.

Idea	Qué es	Por qué es nueva	Riesgo principal
Cámara + radar (con tu compañero)	Sección 6.2, opción B y luego C.	Radar + gaussianas para predicción sin mapa.	Deriva hacia percepción.
Arreglo de CMP (brazos A y B)	Tu propuesta actual [Repo `FIRST_EXPERIMENT_PROPOSAL.md`].	El brazo A es un arreglo de código; el B es la parte nueva.	El brazo A solo no da para paper.

Cómo encajan. El benchmark (paper 1) incluye el análisis por dificultad. El método (paper 2) junta las tres ideas azules de arriba (retraso, confianza y propuestas de la RSU) en un solo predictor calibrado. Esa combinación ya es una contribución con identidad propia, y no "QCNet en V2X". El arreglo de CMP queda como experimento de calentamiento de una o dos semanas, no como paper.

12. Plan de ruta nuevo, centrado 100 % en V2X

El cambio principal respecto a tu `PHD_ROADMAP.md`: el primer paper deja de ser single-agent (calibración en AV2 o generalización de mapas) y pasa a ser V2X desde el principio, con el benchmark unificado. Las dos ideas que tenías para el año 1, calibración y robustez, no se pierden: entran como ejes de ese benchmark, aplicados a V2X.



Plan de ruta propuesto · 5 fases, 4 puertas de paso, 1 línea paralela

12.1 Fase 0 · Suelo V2X (noviembre 2026 – enero 2027)

- [ ] Pedir y descargar **V2X-Seq-TFD**. Comprobar el acceso desde España primero (sección 10.4).
- [ ] Descargar **V2X-Traj** (Google Drive, desde el repo de V2X-Graph).
- [ ] Añadir al bench Docker **V2X-Graph** (código + checkpoint), **Co-MTP** (código) y **V2I_trajectory_prediction** (V2INet). Este último ya está en `setup.sh --all`, solo falta el Docker [Repo].
- [ ] Reproducir dos cifras publicadas en V2X-Seq: HiVT y V2X-Graph con su checkpoint. **Puerta: ambas dentro de un ±5 % de lo publicado.**
- [ ] Validar el checkpoint de CMP solo en V2V4Real (Track A de `TRAINING_PLAN.md`) y hacer el brazo A del arreglo como calentamiento de 1 o 2 semanas.
- [ ] **Aparcar** lo que no está en el camino V2X. Que termine lo que ya corre (SceneInformer, GameFormer); no lanzar los entrenamientos completos de MTR ni de TrajFlow en WOMD; dejar UniAD.

12.2 Fase 1 · Paper 1, benchmark V2X (febrero – junio 2027)

- Protocolo único en V2X-Seq y V2X-Traj, con 5 o 6 métodos re-entrenados y varias semillas (sección 10.3).
- Ejes: precisión, calibración (brier, NLL), robustez a retraso y pérdidas, coste, y tramos de dificultad y oclusión (sección 4.2).
- **Puerta: al menos un hallazgo que cambie el ranking** (por ejemplo, que el mejor en minADE no sea el mejor calibrado o el más robusto). Sin eso, el paper es solo una tabla.
- Envío: arXiv en cuanto esté (verano de 2027) y luego IEEE T-ITS o RA-L, que no tienen fecha límite. Como conferencia, IV 2028, que suele cerrar entre enero y febrero. Las fechas límite son aproximadas; hay que comprobarlas cada año.

12.3 Fase 2 · Paper 2, el método (julio 2027 – febrero 2028)

- Predictor relativo / query-centric con: retraso como tiempo relativo, token de confianza por fuente, propuestas de la RSU como anchors y probabilidades calibradas (secciones 7 y 11).
- Ablaciones: cada pieza por separado, comparado con V2X-RECT si su código aparece; joint ligero como ablación.
- **Puerta: mejora en precisión y en calibración bajo retraso realista, medida en tu propio benchmark.**
- Envío: RA-L (sin fecha límite, con opción de presentarlo en ICRA o IROS) o ITSC 2028, que suele cerrar en marzo o abril.

12.4 En paralelo · Paper conjunto con tu compañero (2027)

Opción B de la sección 6.2. Que su ritmo no frene el tuyo: si se retrasa, se mueve; los papers 1 y 2 no.

12.5 Fase 3 · Datos reales y joint (2028)

- Validación en UrbanIng-V2X y CAMASA (mensajes reales con pérdidas y retrasos reales).
- Capítulo de joint en la RSU.
- **Puerta: un dataset real adicional utilizable para validar fuera de V2X-Seq.** Candidatos: UrbanIng-V2X, CAMASA y V2XPnP-Seq.

12.6 Fase 4 · Tesis (2029)

Ablaciones finales, escritura y defensa. Hilo de la tesis: **"predicción cooperativa que sabe cuánto fiarse: precisión, calibración y robustez a la comunicación real"**.

12.7 Qué cambiar en tu repo

- **`PHD_ROADMAP.md`**: sustituir "Year 1 (remainder)" por la Fase 0. Mover "calibration/regret" y "generalization" a ejes del benchmark V2X.
- **`FIRST_EXPERIMENT_PROPOSAL.md`**: dejar el brazo A como calentamiento. Mover el brazo B a la idea "confianza por fuente" del paper 2.
- **`RECENT_V2X_LITERATURE.md`**: añadir V2X-RECT, I2XTraj, MSMA, UniV2X, Co-P&P (ago 2026) y SPARC.
- **`DATASETS.md`**: añadir V2X-Seq-TFD y V2X-Traj como prioridad.

13. Fuentes

Del proyecto: tus 11 PDFs, `Top-Papers-Readed` v2, el doc de respuestas, el glosario, `Fixing CMPs Prediction Aggregation Module.pdf` y, del repo `Maarioo01/Motion-Prediction` (commit 2bd3d1d): `PHD_ROADMAP.md`, `FIRST_EXPERIMENT_PROPOSAL.md`, `TRAINING_PLAN.md`, `RECENT_V2X_LITERATURE.md`, `DATASETS.md`, `REPO_ASSESSMENT.md`, `MODELS_OVERVIEW.md` y `README.md`.

Web, páginas abiertas el 4–5 de noviembre de 2026:

- **Corpus y paradigmas:** Awesome-Trajectory-Motion-Prediction-Papers · Narrowing the coordinate-frame gap · GoRela · SIMPL · ADAPT · SceneMotion · DeMo · RealMotion · SMART · BeTop · EMP · Forecast-MAE · HPNet · SmartRefine · MTR++ · MotionLM · SEPT · ModeSeq · MotionDiffuser · FJMP · AutoBots · THOMAS · M2I · BiFF ·

R-Pred · GANet · HDGT · MacFormer · FIMP · DESTINE · PBP · TrafficBots · LAformer · EDA · DONUT · SHARP · DriveGATr · Trajectory Mamba · DriveGPT · JAM · Recover to Predict

- **V2X:** V2X-RECT · V2INet · I2XTraj · CAMNet · V2XPnP · Collaborative Trajectory Prediction via Late Fusion · MSMA · Co-P&P (Wan et al.) · UniV2X · Código de Co-MTP · Repo de V2X-Graph · DAIR-V2X-Seq · V2X-Radar
- **Joint:** Joint Metrics Matter · Retos de Waymo 2025
- **Dificultad y datos:** TAROT · Den-TP · Ensemble of Pre-Trained Models for Long-Tailed Trajectory Prediction · Beyond Features (Bosch)
- **UniTraj:** Repo de UniTraj · Citas en Semantic Scholar · Closing the Loop · ControlledShifts
- **Sensores y colaboración:** GaussianCaR · MoST · WOMD-LiDAR · MGTR · Valeo4Cast · SpaRC-AD · Gu et al., BEV directo para predicción · Gaussian Splatting colaborativo
- **Entrenamiento y calibración:** Annealed Winner-Takes-All · Wu et al., WTA y GMM · Evidential Uncertainty · SPARC
- **Jev:** TypeSafe AI · MindStudio · Fortune · TrueFoundry

No pude leer: el PDF de Makansi et al. (ICCV 2021), así que su definición la tomo de cómo la citan UniTraj y los trabajos posteriores. Tampoco JACoP, que además resultó ser de peatones y no entra en el recuento.